

Aprendizaje Profundo

Facultad de Ingeniería
Universidad Popular del
Cesar



Dr. José Ramón Iglesias

DSP-ASIC BUILDER GROUP

Director Semillero TRIAC

Ingeniería Electrónica

Universidad Popular del Cesar


Redes Neuronales Convolucionales

Convolutional Neural Network (CNN)

- . Introducción
- . Kernel, limites y padding
- . Arquitectura base de ejemplo
- . ¿Ventajas?
 - Sparse interaction
 - Parameter sharing
- . Capa Pooling
- . Resumen de capas CNN.
- . Práctica con capas CNN
- . Back propagation en CNN
- . Implementación y práctica
- . ¿Que hay en los kernels?

Redes Neuronales Convolucionales - Introducción

Arquitectura de red neuronal **favorita** para el trabajo con imágenes (o datos que tengan **relación espacial**)



Array de 2d [$m+1 \times n+1$]

Ejemplo: imagen de $m+1 \times n+1$ pixeles


con 3 canales (RGB)

Redes Neuronales Convolucionales - Introducción

... o datos que tengan **relación espacial**...


Array de 1d $[1 \times n+1]$

Ejemplo: señal temporal muestreada




“...medical volumetric images (e.g., CT scans, MRI scans) or video sequences [...] to capture spatial and temporal dependencies “

<https://medium.com/@saba99/3d-cnn-4ccfah119cc2>



Redes Neuronales Convolucionales - Introducción

Otros ejemplos de array 2d: espectrograma



DEBE EXISTIR INFORMACIÓN CON RELACIÓN ESPACIAL EN LAS DIMENSIONES DEL ARRAY

CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Introducción

Su nombre “CONVOLUCIONALES” provienen de que en su interior realizan operaciones de convolución.

Operación en 1D

- Conv. continua $y(t) = x(t) * w(t) = \int_{-\infty}^{\infty} x(\tau) w(t - \tau) d\tau$

- Conv. discreta $y[n] = x[n] * w[n] = \sum_{\tau=-\infty}^{\infty} x[\tau] w[n - \tau]$

CONVOLUTIONAL NEURAL NETWORK (CNN)


Redes Neuronales Convolucionales - Introducción

Convolución (ejemplo gráfico 1d)

$$y[n] = x[n] * w[n] = \sum_{\tau=-\infty}^{\infty} x[\tau] w[n - \tau]$$

$t = 0.$

$w[-\tau]$



<http://amber.feld.cvut.cz/vyu/eo2/english/lectures.htm>

Conv. está ampliamente usado en el análisis de señales y sistemas

CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Introducción

CONVOLUCION 2d – INPUT – KERNEL – OUTPUT - LIMITES

$$S[i, j] = I[i, j] * K[i, j] = \sum_m \sum_n I[m, n] K[i - m, j - n]$$

PROP. CONMUTATIVA

$$S[i, j] = K[i, j] * I[i, j] = \sum_m \sum_n K[m, n] I[i - m, j - n]$$


El kernel es entrenado por la red!
(son sus parámetros o pesos
sinérgicos)

CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Introducción

Convolución (ejemplo gráfico 2d)


El kernel suele tener dimensión impar para definir bien su centro



CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Introducción

FLIPPED CONVOLUTION or CROSS-CORRELATION

$$S[i, j] = K[i, j] \otimes I[i, j] = \sum_m \sum_n I[i + m, j + n] K[m, n]$$


CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Introducción

Convolución y número de canales

Se aplica 1 kernel x canal y se suma todo.

Se suelen emplear varios kernels por capa, para poder “aprender” varias cosas.

Cada kernel podrá “aprender” un feature, que expresará en su salida si lo detecta.

	A	B	C	D	E	F	G	H	I	J	K	L	M	N	O	P	Q	R	S	T	U	V	W	X	Y
1																									
2																									
3																									
4																									
5																									
6																									
7																									
8																									
9																									
10																									
11																									
12																									
13																									
14																									
15																									
16																									
17																									
18																									
19																									
20																									
21																									

↑

PARAMETROS

↑


SALIDA A

CONVOLUTIONAL NEURAL NETWORK (CNN)


Redes Neuronales Convolucionales - Bordos (límites) y padding

padding:
'valid',
'same' or
tuple


(a) "valid" mode






(b) "same" mode



(c) "full" mode



padding_mode:
'zeros',
'reflect',
'replicate' or
'circular'



CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Bordes (límites) y padding

valid $\rightarrow$ no se agregan ceros a I, resultado reducido tal cual se vio.

$$S_{\text{valid}}[i - m + 1, j - n + 1]$$

same $\rightarrow$ se agregan ceros a I para que S sea del mismo tamaño que I.

$$S_{\text{same}}[i, j]$$


full $\rightarrow$ se agregan ceros a I para que el K entre completo.

$$S_{\text{full}}[i + m - 1, j + n - 1]$$

CONVOLUTIONAL NEURAL NETWORK (CNN)

Redes Neuronales Convolucionales - Arquitectura base de ejemplo

Arquitectura típica



CAPA DE CONVOLUCIÓN

Redes Neuronales Convolucionales - ¿Ventajas? Sparse interaction

Entonces...

¿Dónde está la ventaja de usar CNN?

sparse interaction / sparse connectivity o sparse weight
sparse → escaso


- El KERNEL es de dimensiones muy inferiores al tamaño de la imagen (INPUT) a procesar.
- El uso de un KERNEL permite tener interacciones locales de entradas con sus respectivas salidas.
- Las dimensiones del KERNEL indicarán cuanta “vecindad” analizan en cada posición donde sea evaluado.

CAPA DE CONVOLUCIÓN


Redes Neuronales Convolucionales - ¿Ventajas? Sparse interaction

sparse interaction

K[i] - kernel



S[i] - output




x[i] - input

CAPA DE CONVOLUCIÓN


Redes Neuronales Convolucionales - ¿Ventajas? Sparse interaction

sparse interaction



vs

fully connected layer



Visto desde la salida

CAPA DE CONVOLUCIÓN



Redes Neuronales Convolucionales - ¿Ventajas? Sparse interaction

sparse interaction

vs

fully connected layer

Visto desde la entrada




CAPA DE CONVOLUCIÓN

Redes Neuronales Convolucionales - ¿Ventajas? Sparse interaction

sparse interaction

in deep CNN



Redes Neuronales Convolucionales - ¿Ventajas? Parameter sharing

parameter sharing


- El uso de un mismo KERNEL para una capa dada, implica que los parámetros (pesos sinápticos w_{ij}) se comparten.
- Esto permite optimizar dicho KERNEL para que sea capaz de detectar **algo específico** (un borde por ejemplo).
- De esta manera, el KERNEL entrenado, será capaz de detectar **algo específico** en cualquier lugar donde se aplique el KERNEL en la foto de entrada (INPUT).

Redes Neuronales Convolucionales - ¿Ventajas? Parameter sharing

parameter sharing

“...detectar **algo específico** en cualquier lugar donde se aplique el KERNEL ...”

- Esa propiedad se llama **equivariancia a la traslación** (**translation equivariance**) y es natural de la convolución.



CAPA DE CONVOLUCIÓN

Redes Neuronales Convolucionales - ¿Ventajas? Parameter sharing


parameter sharing

Compartir parámetros permite utilizar más de 1 vez un mismo pámetro...

Conv layer

VS

fully conected layer



CAPA DE CONVOLUCIÓN

Redes Neuronales Convolucionales - ¿Ventajas?

sparse interaction + parameter sharing

- Hay una reducción drástica de los parámetros a entrenar y a almacenar.
- Supongamos una capa de m entradas y n salidas...

**Conv layer con
KERNEL de tamaño k**

$$O(k \times n)$$


(cada kernel tendrá 1 salida)

fully connected layer

$$O(m \times n)$$

Redes Neuronales Convolucionales - ¿Ventajas?

sparse interaction + parameter sharing (edge detecting)



Conv layer.

Aprox 267960 float op.


fully connected layer

Aprox 16000000000 float op.

Redes Neuronales Convolucionales - Stride

stride

- Regula los pasos en que avanza la convolución.
- Es como hacer un downsampling de la salida.




Redes Neuronales Convolucionales - Capa de activación

CAPA DE

ACTIVACIÓN/DETECCIÓN

- Es una capa NO LINEAL como las ya conocidas.
- Relación entrada/salida 1/1.
- No se optimizan pesos sinápticos.




Redes Neuronales Convolucionales - Capa de pooling

(POOLING = GROUPING OF ASSETS)

- Es similar a la CONV (tiene size y stride), pero aplica un operador matemático específico en lugar de un KERNEL.
- Se busca una reducción de dimensiones de la entrada con operadores que permitan detectar features.
- Como salida, da un valor característico de todos los features de entrada de la entrada.
- **No se optimizan pesos sinápticos** (solo tiene hiper-parámetros)

CAPA DE POOLING (GROUPING OF ASSETS)

Redes Neuronales Convolucionales - Capa de pooling



<https://iq.opengenus.org/pooling-layers/>

Redes Neuronales Convolucionales - Capa de pooling


“...operadores que permitan detectar features.”

- **Max pooling** → de todos, dame el máximo (¿está el feature acá?)
- **Average pooling** → de todos, dame el promedio (¿qué prob de encontrar el feature tengo?)
- **Power Average pooling** → norma p de un vector. $f(X) = \sqrt[p]{\sum x_i^p}$
- **Adaptive pooling**
- **Global, fractional**

Redes Neuronales Convolucionales - Capa de pooling

¿Qué ventaja gana haciendo pooling?

- Reducción de dimensión (resumen estadístico de la entrada)
- **Translation invariant → invariancia al desplazamiento.**
- **Permite lograr una detección que no depende de la posición (es invariante a la posición de dicho feature)**



Redes Neuronales Convolucionales - Capa de pooling

Translational invariance

Translation Invariance



<https://kamathhrishi.github.io/MyWebsite/jekyll/update/2022/06/10/modelvsdataml.html>


Redes Neuronales Convolucionales - Capa de pooling

Translational invariance.... ¿?


Una cara tiene:

- 2 ojos
- 1 nariz
- 1 boca
- 2 orejas

... ¿correcto?





Not Face



Face

Redes Neuronales Convolucionales - Capa de pooling

rotational invariance



Polling over channels!

Libreria -> einops

<https://stackoverflow.com/questions/46562612/pytorch-maxpooling-over-channels-dimension>

Redes Neuronales Convolucionales - Capa de pooling


rotational/translational/scale INvariance or EQUivariance

**LE ENSEÑÉ A MI TÍO A USAR EL PHOTOSHOP
Y UNA SEMANA DESPUÉS ME MANDÓ ESTO...**



RESUMEN MODULO DE CNN

Redes Neuronales Convolucionales - Resumen de capas CNN



Hiper parámetros (se eligen)	Parametros (se entrenan)
Pooling func Kernel size stride	ninguno
Function Function param	ninguno
Nro kernel (CH out) Kernel size Padding Stride	Nro kernel * (kernel size**2 * CH input + 1)

Redes Neuronales Convolucionales - Práctica con capas CNN

Unos minutos de descanso...

coffee / mate / pizza break



Luego... parte práctica 1

Redes Neuronales Convolucionales - Back-propagation en CNN

**Y ahora....
...back-propagation...**



Redes Neuronales Convolucionales - Implementación

Parte práctica 2

**Unos minutos de
descanso...**

coffee / mate / pizza break

Redes Neuronales Convolucionales – Estudio de hiperparámetros

Se parte de un modelo base y se ejecuta un grid_search de hiperparámetros para 3 datasets (MNIST, FashionMNIST y CIFAR10)

Modelo base:

```
num_conv_blocks=3,  
channels=(8,16,32),  
kernel_size=5,  
padding="same",  
dropout=0.3,
```




Receta:

```
epochs=20,  
batch_size=64,  
learning_rate=1e-4,  
optimizer=Adam,  
patience=3,  
relative_improvement_factor=0.01.
```

Experimento	Qué se varía	Valores / rango
exp_1	kernel_size	[3, 5, 7, 9]
exp_2	num_conv_blocks channels asociados	[2, 3, 4] 2 -> (8,16), 3 -> (8,16,32), 4 -> (8,16,32,64)
exp_3	channels	[(8,16,32), (16,16,16), (16,32,64)]
exp_4	padding arquitectura fija	[0, 1, 2] 2 bloques, channels=(8,16), kernel_size=5
exp_5	batch_size	[32, 64, 128]
exp_6	learning_rate	[1e-4, 5e-4, 1e-3]
exp_7	momentum en SGD	[0.0, 0.5, 0.9] con lr=1e-2
exp_8	dropout	[0.0, 0.2, 0.3, 0.5, 0.7]
exp_9	data augmentation arquitectura fija	[False, True] 4 bloques, channels=(16,32,64,128), kernel_size=9, padding="same"




Redes Neuronales Convolucionales – Estudio de hiperparámetros

exp_1	kernel_size	[3, 5, 7, 9]
-------	-------------	--------------






Redes Neuronales Convolucionales – Estudio de hiperparámetros

exp_2	num_conv_blocks channels asociados	[2, 3, 4] 2 -> (8,16), 3 -> (8,16,32), 4 -> (8,16,32,64)
-------	---------------------------------------	---




Redes Neuronales Convolucionales – Estudio de hiperparámetros


exp_3	channels	[(8,16,32), (16,16,16), (16,32,64)]
-------	----------	-------------------------------------



Redes Neuronales Convolucionales - ¿que hay en los kernels?



Redes Neuronales Convolucionales - ¿que hay en los kernels?



Example of features that the filters in a convolution layer look for at different levels in a network. The deeper into the network (higher level), the more complex the features are. Source: (F.-F. Li & Karpathy, 2015).