

Aprendizaje Profundo

Facultad de Ingeniería
Universidad Popular del
Cesar



Dr. José Ramón Iglesias

DSP-ASIC BUILDER GROUP

Director Semillero TRIAC

Ingeniería Electrónica

Universidad Popular del Cesar

REPRESENTATION LEARNING

AUTOENCODER / EMBEDDINGS

Representation learning

. Autoencoders

Undercomplete vs regularized
AE

Manifold learning

Variational AE

. Embeddings

Embeddings vs one-hot encoding

False task training

Representation learning

¿Cuántos es 240 dividido 6?

Y... ¿Cuánto es CCXL dividido VI?

Una misma información puede ser representada en distintas maneras → una representación será mejor que otras si la tarea que queremos realizar nos resulta mas facil empleando dicha representación

Representation learning

Representation learning (featuring engineer automático)

Obtener **features** de unlabeled data siguiendo un entrenamiento supervisado bajo una NN secundaria (autoencoder o semejantes) siguiendo una false task.

- + Reducción de dimension del input
- + Encontrar latent variables
- + Semi supervised learning


Se reduce la complejidad del dataset → se reducen las anomalías y el ruido

Hacemos operaciones sobre ellos

- Clustering maps
- Reducción de dimensiones
- Operadores lógicos (auto > bicicleta?)
- Medir distancias (manzana mas cerca que torta?)
- Proyecciones o multiplicaciones

Representation learning

Representation learning





Mas datos (de entrenamiento) no necesariamente garantiza llegar a un buen modelo.

Con features correctos, las tarea de la red puede ser mejor alcanzada.

When the learned features are passed into the supervised learning algorithm, it can improve the prediction accuracy up to 17%.

[<https://dl.acm.org/doi/10.1145/3303772.3303795>].

Autoencoders



$$L(x, g(f(x))),$$

PCA??

undercomplete autoencoders vs regularized autoencoders

Autoencoders

Undercomplete autoencoders vs **Regularized** autoencoders

Si un autoencoder tiene capacidad suficiente copiará la entrada (aprende la función identidad).

Se reduce la capacidad del autoencoder (**undercomplete** ...) para que aprenda los “aspectos relevantes” de la entrada. Aprenden la *latent variable* del dataset.

Otra manera es “regularizar” sus pesos en el entrenamiento... **regularized** ... para que aprenda otras características del dataset.

$$L(\mathbf{x}, g(f(\mathbf{x}))) + \Omega(\mathbf{h}, \mathbf{x}),$$

Autoencoders

Sparse autoencodes → limitación de activación neuronas

$$L(\mathbf{x}, g(f(\mathbf{x}))) + \Omega(\mathbf{h}, \mathbf{x}), \quad \Omega(\mathbf{h}) = \lambda \sum_i |h_i|, \quad \text{Regularización L1}$$

- **Sparse activation** – Para una entrada dada, la mayoría de los h_i producirán una activación muy pequeña.
- Para una h_i dada, su activación promedio (sobre todas las muestras) será un valor cercano a cero.
- Esto previene que el autoencoder use todas las h_i al mismo tiempo y fuerza a un uso reducido de h_i

Sparse autoencodes → para **obtener features** para otra tarea → pre-training.

Autoencoders

Constractive autoencoders CAE

$$\Omega(\mathbf{h}) = \lambda \left\| \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} \right\|_F^2.$$

El objetivo es aprender una representación que sea **poco sensible a pequeñas variaciones** en los datos de entrada.

- Inputs similares tendrán similares representaciones. Se fuerza al modelo a aprender un vecindario reducido de $\mathbf{x}$ y mapearlo a un vecindario reducido de h_i
- Undercomplete + constractive $\rightarrow$ se aprenden dh_i/dx pequeñas. Solo un número pequeño de h_i (que se corresponden con un número reducido de direcciones en $\mathbf{x}$), pueden tener una derivada considerable.

Constractive autoencodes $\rightarrow$ hace que el **encoder** no varíe mucho ante pequeños cambios en $\mathbf{x}$


Autoencoders

Manifold learning con

- **Manifold** es un espacio N-dimensional, de menor dimensión del espacio original donde los datos se concentran.
- Si nos desplazamos dentro del manifold del MNIST, siempre encontraremos un número MNIST.
- Si nos salimos de dicho **manifold**, no encontraremos un número MNIST.

TODAS LAS NN "ENCUENTRAN" EL
MANIFOLD DE LOS DATOS

https://www.youtube.com/watch?v=QHj9uVmwA_0&t=12s&ab_channel=ArtemKirsanov



Autoencoders

Manifold learning con
autoencoders




<https://www.kaggle.com/apapiu/manifold-learning-and-autoencoders>

Autoencoders

Variational autoencoder - VAE

Encoder genera el espacio latente bajo una función de densidad de probabilidad.




- Otorga control sobre cómo se distribuye el espacio latente de nuestro modelo.
- Luego de entrenar, se toma una muestra aleatoria de dicha función de densidad de probabilidad para alimentar al decoder.
- En VAE el espacio latente Z se ve como una variable latente con una probabilidad $P(Z)$ de que dicha variable z pertenezca al manifold de los datos de entrada.

Autoencoders

Variational autoencoder - VAE

$$\begin{aligned} Z_{\mu}, Z_{\ln(\sigma^2)} &= \text{enc}(X) \\ \epsilon &\in N(0, 1) \\ Z &= Z_{\mu} + \epsilon \sqrt{\exp(Z_{\ln(\sigma^2)})} \\ X_{\text{recon}\mu} &= \text{dec}(Z) \end{aligned}$$




Autoencoders


Reparameterization Trick

$$\begin{aligned}Z_\mu, Z_{\ln(\sigma^2)} &= \text{enc}(X) \\ \epsilon &\in N(0, 1) \\ Z &= Z_\mu + \epsilon \sqrt{\exp(Z_{\ln(\sigma^2)})} \\ X_{\text{recon}_\mu} &= \text{dec}(Z)\end{aligned}$$

Original form



Reparameterised form




◆ : Deterministic node
● : Random node


[Kingma, 2013]
[Bengio, 2013]
[Kingma and Welling 2014]
[Rezende et al 2014]

Autoencoders

Denoising autoencoders



$$||g(f(\tilde{x})) - x||^2$$




Autoencoders

ver github autoencoder


Autoencoders

VAE autoencoder
convolucional


KI=0



KI=0.2
5




KI=0.7
5




Autoencoders

MLP
Zdim: 32




MSE:
0.0431

sparse MLP
Zdim: 32
L1: 5e-4



MSE:
0.0457

VAE MLP
Zdim: 32
Kl: 1e-4




MSE:
0.0440

Autoencoders

MLP
Zdim: 32

sparse MLP
Zdim: 32
L1: 5e-4

VAE MLP
Zdim: 32
Kl: 1e-4



MSE:
0.0431

MSE:
0.0457

MSE:
0.0440

¡Un merecido descanso!



embeddings

Embeddings → se trata de crear espacio continuo de representación de los inputs.

Se crean ad-hoc o dentro del frame de la NN.

Cada palabra es representada por un vector N-dimensional en un subespacio continuo (en el embedding)

Perro → [e1, e2, e3, ... eN]

La posición que toma el vector N-dimensional se entrena a partir de su entorno.


embeddings

Ejemplo: vocabulario 4 palabra, embedding dimensión 2:

“pesos” inicializados “rand”

Perro	→ [e00, e01] = [0.123, 0.541]
Gato	→ [e10, e11] = [0.287, 0.459]
Caballo	→ [e20, e21] = [0.594, 0.180]
Árbol de levas	→ [e30, e31] = [0.251, 0.328]

Entrenamiento
supervisado
siguiendo una
false task



“pesos” entrenados

Perro	→ [e00, e01] = [0.873, 0.241]
Gato	→ [e10, e11] = [0.921, 0.147]
Caballo	→ [e20, e21] = [0.723, 0.541]
Árbol de levas	→ [e30, e31] = [0.003, 0.981]


embeddings

Embeddings

One-hot-encoding
!=
Word embedding

- Reducción de dimensiones
- Se aprenden propiedades intrínsecas de palabras que pertenecen al mismo grupo.

Vocabulary:
Man, woman, boy,
girl, prince,
princess, queen,
king, monarch



	1	2	3	4	5	6	7	8	9
man	1	0	0	0	0	0	0	0	0
woman	0	1	0	0	0	0	0	0	0
boy	0	0	1	0	0	0	0	0	0
girl	0	0	0	1	0	0	0	0	0
prince	0	0	0	0	1	0	0	0	0
princess	0	0	0	0	0	1	0	0	0
queen	0	0	0	0	0	0	1	0	0
king	0	0	0	0	0	0	0	1	0
monarch	0	0	0	0	0	0	0	0	1


Vocabulary:
Man, woman, boy,
girl, prince,
princess, queen,
king, monarch



	Femininity	Youth	Royalty
Man	0	0	0
Woman	1	0	0
Boy	0	1	0
Girl	1	1	0
Prince	0	1	1
Princess	1	1	1
Queen	1	0	1
King	0	0	1
Monarch	0.5	0.5	1

embeddings

Embeddings → interpretaciones




Male-Female


$$[\text{king}] - [\text{man}] + [\text{woman}] = [\text{queen}]$$

embeddings

Embeddings → interpretaciones



$$[\text{Italy}] - [\text{Rome}] + [\text{Berlín}] = [\text{Germany}]$$



<https://arxiv.org/abs/1310.4546v1>

Distributed Representations of Words and Phrases and their Compositionality

embeddings

Embeddings → metricas de similitud

Distancia
euclidea

$$\sqrt{\sum_{i=0}^n (A_i - B_i)^2}$$

Similitud del
coseno


$$\frac{A \cdot B}{\|A\| * \|B\|}$$

Producto punto

$$\sum_{i=0}^n (A_i * B_i)$$


embeddings

Embeddings → entrenamiento en base del contexto



embeddings

Embeddings → entrenamiento en base del contexto



Entrenamiento con predictores, usando esquemas tales como:
Skip Gram o Continuous Bag of Words (CBOW) ...
siguiendo una false task


embeddings

Embeddings → CBOW y skip-gram


Aquí me pongo a cantar
al compás de la vigüela,
que el hombre que lo desvela
una pena extraordinaria,
como la ave solitaria con el cantar se
consuela.

Pido a los Santos del Cielo
que ayuden mi pensamiento,
les pido en este momento que voy a
cantar mi historia.

“Martín Fierro” J. Hernandez



CBOW



Skip-gram

embeddings

Embeddings → no solo se aplica a palabras....

ver
codigo